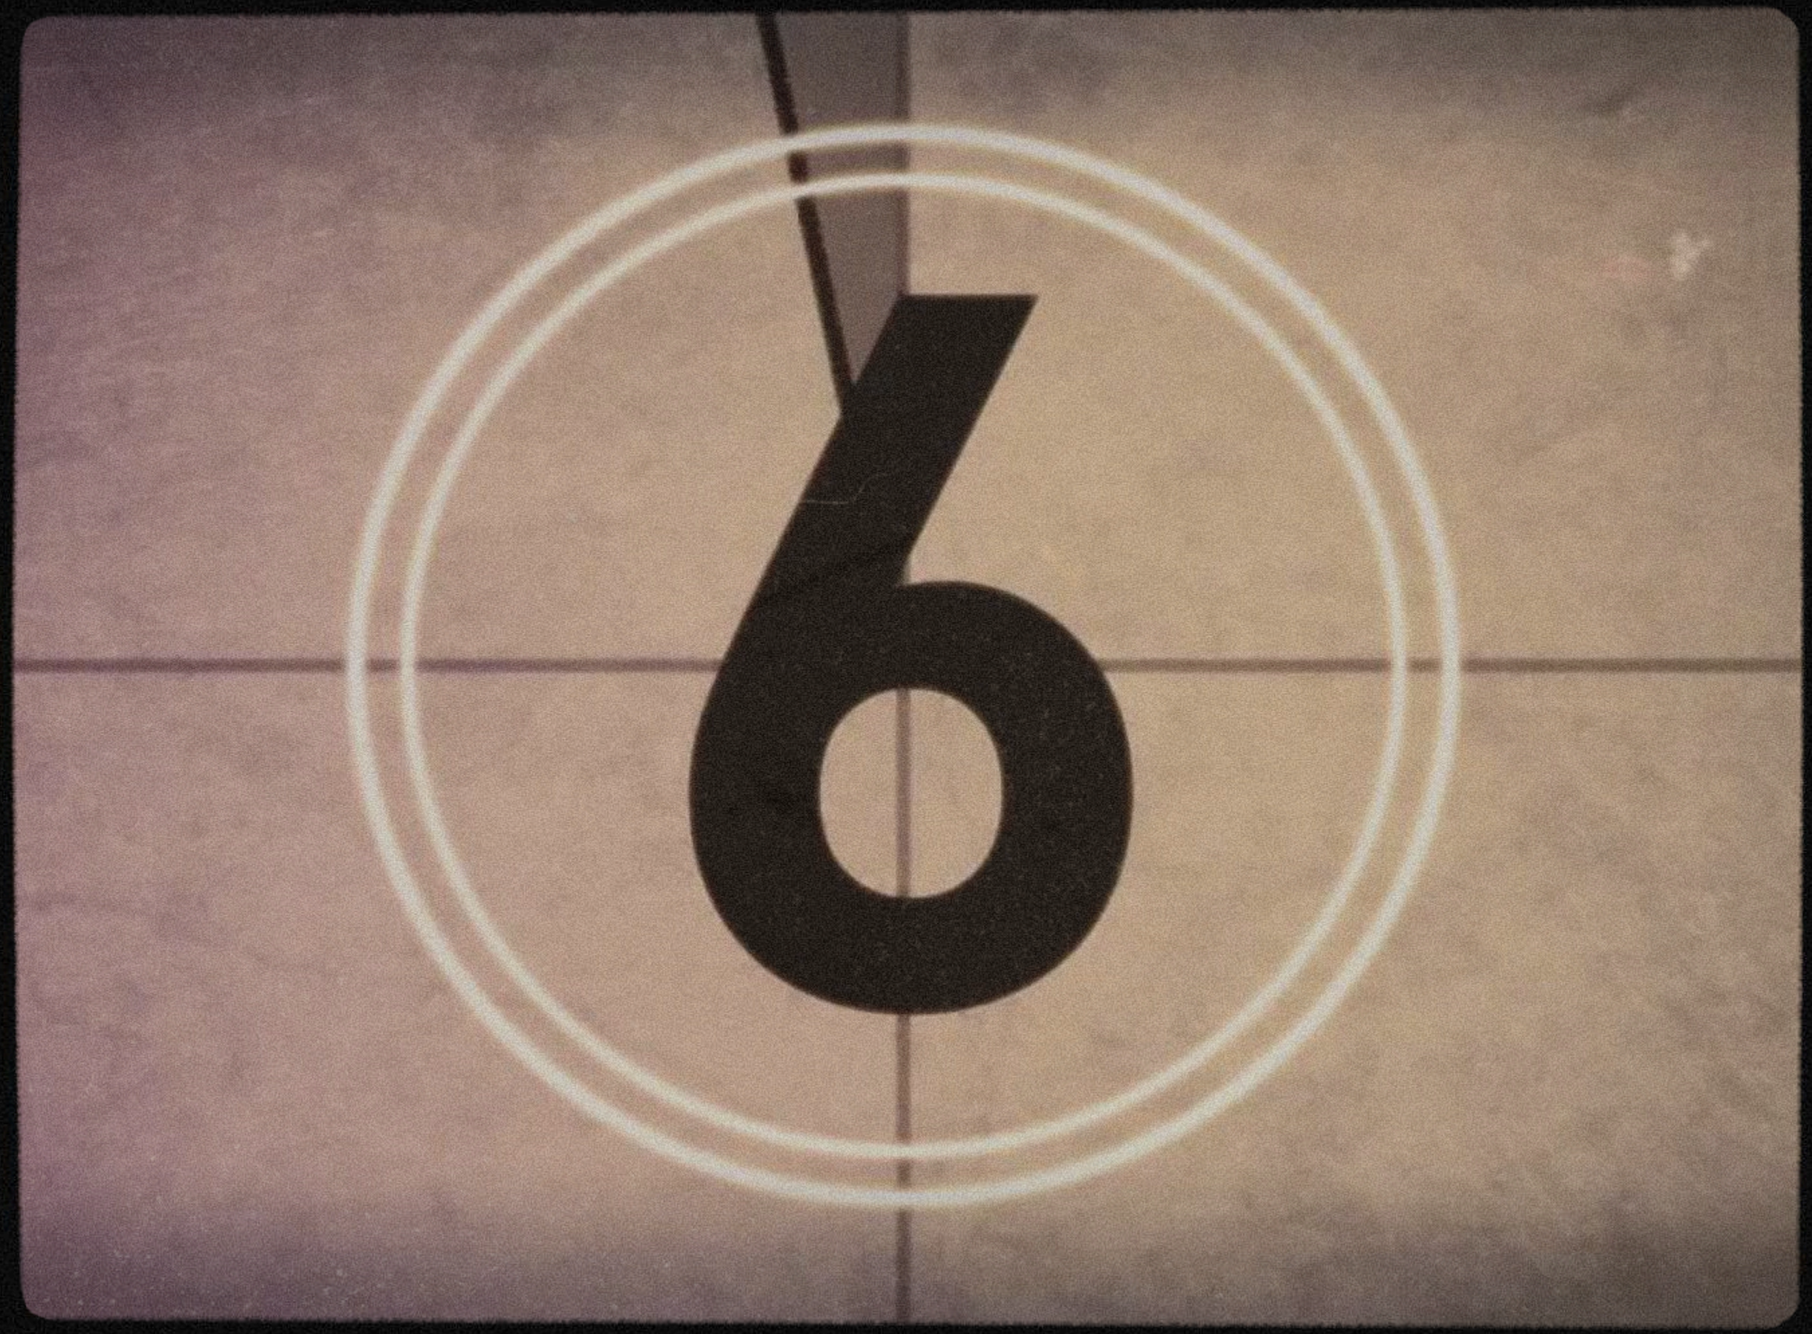
6

HIGHLIGHT
Next Slide
2

INDIAN *movies*

By Mahalanobis

Data: Indian Movies

Pattern

- นักแสดงนำ(*Actor1*)
- ยุค (*Era*)
- ระดับคะแนน (*Rating_Quantiles*)

นักแสดงนำในแต่ละยุคมีเรทติ้งเป็นอย่างไร

```
India_data_cleaned.head()
```

	Name	Year	Duration	Genre	Rating	Votes	Director	Actor 1	Actor 2	Actor 3	Era	Duration_Category	Rating_Quantiles	Votes_Range
0	"space"	2017.0	120.5	Drama	6.4	604.6	J.S. Randhawa	Manmauji	Birbal	Rajendra Bhatia	Streaming Era	Long	Good	0-9999
1	#Gadhvi (He thought he was Gandhi)	2019.0	109.0	Drama	7.0	8.0	Gaurav Bakshi	Rasika Dugal	Vivek Ghamande	Arvind Jangid	Streaming Era	Medium	Excellent	0-9999
2	#Homecoming	2021.0	90.0	Drama, Musical	6.5	1736.9	Soumyajit Majumdar	Sayani Gupta	Plabita Borthakur	Roy Angana	Streaming Era	Medium	Good	0-9999
3	#Yaaram	2019.0	110.0	Comedy, Romance	4.4	35.0	Ovais Khan	Prateik	Ishita Raj	Siddhant Kapoor	Streaming Era	Medium	Poor	0-9999
4	...And Once Again	2010.0	105.0	Drama	6.4	604.6	Amol Palekar	Rajat Kapoor	Rituparna Sengupta	Antara Mali	Streaming Era	Medium	Good	0-9999

#1 Data Cleaning

Next Slide

```python
# convert categorical variables to numerical using one-hot encoding
cat_vars = ['Genre','Director', 'Actor 1', 'Actor 2', 'Actor 3', 'Era', 'Duration_Category','Rating_Quantiles', 'Votes_Range']  #'Director', 'Actor 1', 'Actor 2', 'Actor 3', 'Er
data_encoded = pd.get_dummies(India_data_cleaned, columns=cat_vars)
```

```python
data_encoded
```

	Name	Year	Duration	Rating	Votes	Genre_Action	Genre_Action, Adventure	Genre_Action, Adventure, Biography	Genre_Action, Adventure, Comedy	Genre_Action, Adventure, Crime	...	Votes_Range_500000-509999	Votes_Range_510000-519999	Votes_Ran
0	"space"	2017.0	120.5	6.4	604.6	False	False	False	False	False	...	False	False	
1	#Gadhvi (He thought he was Gandhi)	2019.0	109.0	7.0	8.0	False	False	False	False	False	...	False	False	
2	#Homecoming	2021.0	90.0	6.5	1736.9	False	False	False	False	False	...	False	False	
3	#Yaaram	2019.0	110.0	4.4	35.0	False	False	False	False	False	...	False	False	
4	...And Once Again	2010.0	105.0	6.4	604.6	False	False	False	False	False	...	False	False	

#2 Data EnCoding

Next Slide

```python
selected_columns = [col for col in data_apri.columns if col.startswith('Actor 1')] + \
                   [col for col in data_apri.columns if col.startswith('Era')] + \
                   [col for col in data_apri.columns if col.startswith('Rating_Quantiles')]
```

```python
data_selected
```

	Actor 1_A. Muthu	Actor 1_A. Nairang	Actor 1_A.K. Hangal	Actor 1_A.K. Misra	Actor 1_A.S. Ravindra Babu	Actor 1_Aachi Manorama	Actor 1_Aadar Jain	Actor 1_Aadhi	Actor 1_Aadi Jain	Actor 1_Aadil Abedi
0	False	False	False	False	False	False	False	False	False	False
1	False	False	False	False	False	False	False	False	False	False
2	False	False	False	False	False	False	False	False	False	False
3	False	False	False	False	False	False	False	False	False	False
4	False	False	False	False	False	F				

มีข้อมูลทั้งหมด 11,646 แถว

#3 Column Selection

Next Slide

```python
from mlxtend.frequent_patterns import apriori, association_rules

# ค่าที่ตั้งต้น
min_sup = 0.001

# คำนวณ frequent itemsets
frequentItemsets_Streaming = apriori(data_selected, min_support=min_sup, use_colnames=True)

# สร้างกฎเชื่อมโยง (association rules) จาก frequent itemsets
rules = association_rules(frequentItemsets_Streaming, metric="lift", min_threshold=1)
rules
```

#4 Association Rule

Next Slide

```
pd.concat([rules.head(5), rules.tail(5)])
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
0	(Era_Blockbuster Era)	(Actor 1_Aamir Khan)	0.279581	0.002834	0.001803	0.006450	2.276134
1	(Actor 1_Aamir Khan)	(Era_Blockbuster Era)	0.002834	0.279581	0.001803	0.636364	2.276134
2	(Rating_Quantiles_Excellent)	(Actor 1_Aamir Khan)	0.183840	0.002834	0.001631	0.008874	3.131842
3	(Actor 1_Aamir Khan)	(Rating_Quantiles_Excellent)	0.002834	0.183840	0.001631	0.575758	3.131842
4	(Era_New Hollywood)	(Actor 1_Abhi Bhattacharya)	0.173278	0.002233	0.001374	0.007929	3.551422
843	(Rating_Quantiles_Poor, Era_Blockbuster Era)	(Actor 1_Vinod Khanna)	0.095226	0.004809	0.001116	0.011722	2.437814
844	(Actor 1_Vinod Khanna, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.002490	0.273313	0.001116	0.448276	1.640157
845	(Rating_Quantiles_Poor)	(Actor 1_Vinod Khanna, Era_Blockbuster Era)	0.273313	0.002490	0.001116	0.004084	1.640157
846	(Actor 1_Vinod Khanna)	(Rating_Quantiles_Poor, Era_Blockbuster Era)	0.004809	0.095226	0.001116	0.232143	2.437814
847	(Era_Blockbuster Era)	(Rating_Quantiles_Poor, Actor 1_Vinod Khanna)	0.279581	0.001546	0.001116	0.003993	2.583231

#4 Association Rule

Next Slide

```python
rules_genre_duration_antecedents = rules[
    rules['antecedents'].apply(lambda x: any('Actor' in str(i) for i in x) and any('Era' in str(i) for i in x))
]

# Function to extract actor name from frozenset
def get_actor_name(antecedents_set):
    for item in antecedents_set:
        if 'Actor' in item:
            return item
    return None
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
493	(Actor 1_Ajay Devgn, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.002147	0.273313	0.001460	0.680000	2.487992
499	(Actor 1_Ajay Devgn, Era_Internet Age)	(Rating_Quantiles_Poor)	0.002404	0.273313	0.001116	0.464286	1.698734
505	(Actor 1_Akshay Kumar, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.002490	0.273313	0.001288	0.517241	1.892489

#5 Filter

Next Slide

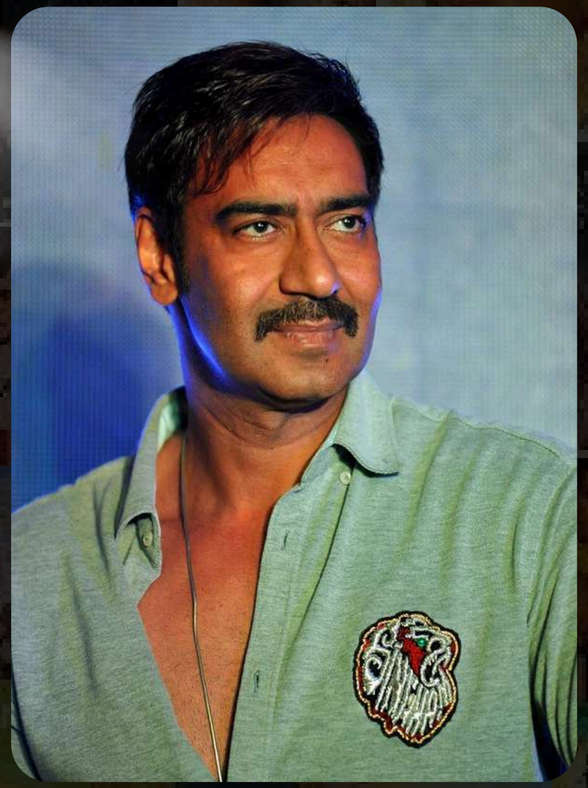

Ajay Devgn

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
492	(Actor 1_Ajay Devgn, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.002147	0.273313	0.001460	0.680000	2.487992
498	(Actor 1_Ajay Devgn, Era_Internet Age)	(Rating_Quantiles_Poor)	0.002404	0.273313	0.001116	0.464286	1.698734

นักแสดงชื่อ Ajay Devgn ในยุค **Blockbuster** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.14% ของข้อมูลทั้งหมด หรือประมาณ 17 เรื่อง**

- โดยมีค่า confidence ≈ 0.68 หมายความว่า นักแสดงชื่อ Ajay Devgn ในยุค Blockbuster มีโอกาสประมาณ 68% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

ในยุค **Internet Age** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.11% ของข้อมูลทั้งหมด หรือประมาณ 13 เรื่อง**

- โดยมีค่า confidence ≈ 0.46 หมายความว่า นักแสดงชื่อ Ajay Devgn ในยุค Internet Age มีโอกาสประมาณ 46% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

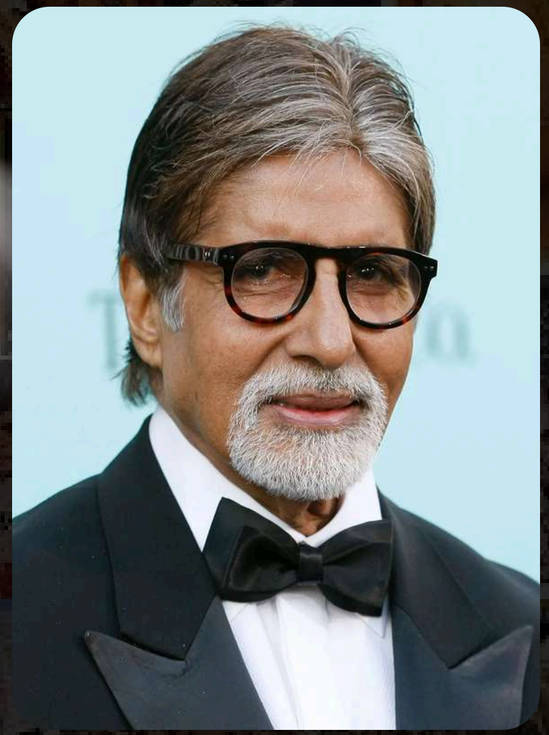

Amitabh Bachchan

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
512	(Actor 1_Amitabh Bachchan, Era_New Hollywood)	(Rating_Quantiles_Excellent)	0.001975	0.183840	0.001116	0.565217	3.074508
517	(Actor 1_Amitabh Bachchan, Era_Blockbuster Era)	(Rating_Quantiles_Excellent)	0.003349	0.183840	0.001030	0.307692	1.673697
522	(Era_Internet Age, Actor 1_Amitabh Bachchan)	(Rating_Quantiles_Excellent)	0.003263	0.183840	0.001116	0.342105	1.860886

ในยุค **New Hollywood** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Excellent คิดเป็น 0.11% ของข้อมูลทั้งหมด หรือประมาณ 12 เรื่อง**

- โดยมีค่า confidence ≈ 0.56 หมายความว่า นักแสดงชื่อ Amitabh Bachchan ในยุค New Hollywood มีโอกาสประมาณ 56% ที่จะได้เรตติ้งดีมากที่สุด
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

ในยุค **Blockbuster** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Excellent คิดเป็น 0.10% ของข้อมูลทั้งหมด หรือประมาณ 11 เรื่อง**

- โดยมีค่า confidence ≈ 0.30 หมายความว่า นักแสดงชื่อ Amitabh Bachchan ในยุค Blockbuster มีโอกาสประมาณ 30% ที่จะได้เรตติ้งดีมากที่สุด
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

ในยุค **Internet Age** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Excellent คิดเป็น 0.11% ของข้อมูลทั้งหมด หรือประมาณ 12 เรื่อง**

- โดยมีค่า confidence ≈ 0.34 หมายความว่า นักแสดงชื่อ Amitabh Bachchan ในยุค Internet Age มีโอกาสประมาณ 34% ที่จะได้เรตติ้งดีมากที่สุด
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

Govinda

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
610	(Actor 1_Govinda, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.003692	0.273313	0.002147	0.581395	2.127217
616	(Actor 1_Govinda, Era_Internet Age)	(Rating_Quantiles_Poor)	0.001460	0.273313	0.001202	0.823529	3.013140

ในยุค **Blockbuster** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.2147% ของข้อมูลทั้งหมด หรือประมาณ 25 เรื่อง**

- โดยมีค่า confidence ≈ 0.58 หมายความว่า นักแสดงชื่อ Govinda ในยุค Blockbuster มีโอกาสประมาณ 58% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

ในยุค **Internet Age** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.12% ของข้อมูลทั้งหมด หรือประมาณ 13 เรื่อง**

- โดยมีค่า confidence ≈ 0.82 หมายความว่า นักแสดงชื่อ Govinda ในยุค Internet Age มีโอกาสประมาณ 82% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

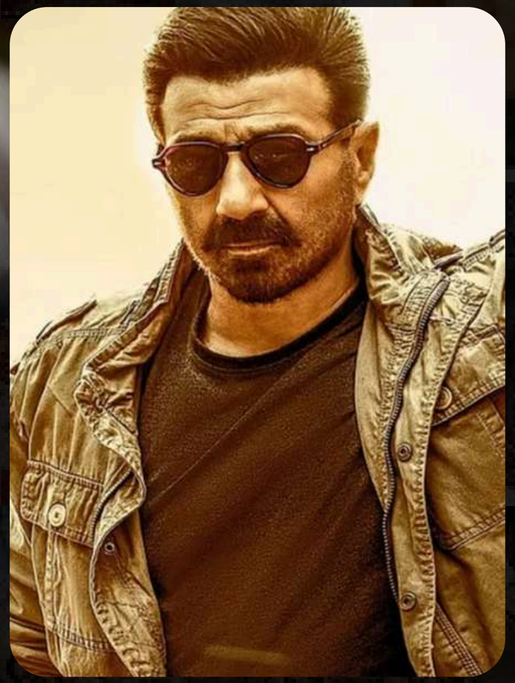

Sunny Deol

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
836	(Actor 1_Sunny Deol, Era_Internet Age)	(Rating_Quantiles_Poor)	0.001460	0.273313	0.001202	0.823529	3.013140
830	(Actor 1_Sunny Deol, Era_Blockbuster Era)	(Rating_Quantiles_Poor)	0.002919	0.273313	0.001116	0.382353	1.398958

ในยุค **Blockbuster** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.12% ของข้อมูลทั้งหมด หรือประมาณ 13 เรื่อง**

- โดยมีค่า confidence ≈ 0.38 หมายความว่า นักแสดงชื่อ Sunny Deol ในยุค Blockbuster มีโอกาสประมาณ 38% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

ในยุค **Internet Age** มีแนวโน้มที่จะได้เรตติ้งอยู่ในกลุ่ม **Poor คิดเป็น 0.11% ของข้อมูลทั้งหมด หรือประมาณ 12 เรื่อง**

- โดยมีค่า confidence ≈ 0.82 หมายความว่า นักแสดงชื่อ Sunny Deol ในยุค Internet Age มีโอกาสประมาณ 82% ที่จะได้เรตติ้งต่ำ
- ค่า lift > 1 เช่นกัน บ่งชี้ว่ามีความสัมพันธ์กันจริง ไม่ใช่แค่บังเอิญ

สมาชิก

กฤตยา นิกรกุล 663020278-5

จิตรลดา นิมินรัมย์ 663020278-5

บงกช เจตวัน 66302028-4

รุ่งแสง กองสุข 663020292-1